



Universidad Nacional
Autónoma de México
Facultad de Ciencias
Almacenes y Minería de
Datos



Tarea 03

Reglas de asociación y clasificación

Profesora: Jessica Santizo Galicia

Ayudantes: Diego Antonio Villalba González, Ares Gael Castro Romero

Integrantes del Equipo:

Brenda Jiménez Ruiz

Irany Solano Marcial

Fecha de entrega:

4 de mayo de 2026, a más tardar a las 23:59



1. Implementación del Algoritmo Apriori

2. Introducción

Este reporte presenta el análisis de reglas de asociación aplicado al dataset del Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP), que contiene registros de personas desaparecidas en México. Este dataset presenta retos del mundo real: 133,887 registros, información protegida legalmente, variables continuas que requieren discretización, y variables con cardinalidad muy alta que necesitan simplificación.

Se implementaron y compararon tres algoritmos:

- **Apriori propio** — implementado desde cero en Python puro
- **Apriori de mlxtend** — usando operaciones vectorizadas de NumPy
- **FP-Growth de mlxtend** — usando la estructura FP-Tree

El objetivo es identificar patrones del tipo:

```
SEXO=Femenino ^ GRUPO.EDAD=12-17 ⇒ ENTIDAD=...  
ENTIDAD=... ^ TEMPORADA=... ⇒ ESTATUS_VICTIMA=...
```

3. Tratamiento de Valores CONFIDENCIAL

Al explorar el dataset encontramos que **49,149 registros (36.7%)** tienen el valor **CONFIDENCIAL** en todas sus columnas de forma simultánea: SEXO, FECHA_NACIMIENTO, FECHA_DESAPARICION, ESTATUS_VICTIMA y MUNICIPIO. Esto indica casos cuya información está legalmente protegida bajo la legislación mexicana, probablemente menores de edad u otras situaciones especiales.

3.1. Decisión tomada: excluir del análisis

Si se mantuvieran estos registros, la regla más frecuente sería:

```
SEXO=CONFIDENCIAL ⇒ ESTATUS_VICTIMA=CONFIDENCIAL  
soporte: 36.7%, confianza: 100 %, lift: muy alto
```

Esta regla no describe ningún patrón real de desaparición — solo refleja la política de protección de datos del sistema de registro. Por tanto tomamos la decisión de excluirlos.



Limitación importante: al excluir este tercio del dataset, los patrones encontrados aplican únicamente al 63.3 % de los casos con información pública. Los patrones en los datos protegidos podrían ser completamente diferentes.

Cuadro 1: Separación de registros por disponibilidad de información

Grupo	Registros	Porcentaje	Decisión
Registros CONFIDENCIAL	49,149	36.7 %	Excluidos — información protegida
Registros con datos públicos	84,738	63.3 %	Base del análisis
TOTAL	133,887	100 %	

4. Preprocesamiento y Discretización

Para aplicar reglas de asociación todas las variables deben ser **categoricas**. Las variables continuas (edades, fechas) deben discretizarse en rangos con sentido.

4.1. Edad al momento de la desaparición

Se calculó la edad restando FECHA_NACIMIENTO de FECHA_DESAPARICION. Se eliminaron fechas de nacimiento anteriores a 1920 (errores de captura) y 64 edades negativas (fecha de desaparición anterior al nacimiento registrado).

Justificación de los grupos: se usan los grupos que nos indica en la tarea, añadiendo infancia (0–11) y adulto mayor (60+) para completar la línea de vida.

Cuadro 2: Distribución de grupos etarios en los registros analizados

Grupo	Rango	Registros	%
Infancia	0–11	2,117	2.5 %
Adolescencia	12–17	3,537	4.2 %
Juventud	18–25	10,514	12.4 %
Adulthood temprana	26–40	19,245	22.7 %
Adulthood media	41–60	9,636	11.4 %
Adulto mayor	60+	2,352	2.8 %
Sin fecha de nacimiento	—	34,125	40.3 %
Total		84,738	100 %



Limitación: el 40.3 % de los registros no tiene fecha de nacimiento registrada. Estos registros no incluyen el ítem GRUPO_EDAD en su transacción pero **no se eliminan** del análisis — simplemente ese campo queda vacío.

4.2. Fecha de desaparición → Temporada

Los 12 meses individuales generarían ítems con soporte bajo. Se agruparon en 4 temporadas del año:

Cuadro 3: Distribución de desapariciones por temporada

Temporada	Meses	Registros	%
Primavera	Mar – May	20,219	23.9 %
Verano	Jun – Ago	20,865	24.6 %
Otoño	Sep – Nov	17,961	21.2 %
Invierno	Dic – Feb	17,533	20.7 %
Sin fecha	—	8,160	9.6 %

La distribución es bastante uniforme entre temporadas, lo que indica que las desapariciones no tienen una marcada estacionalidad.

4.3. Origen del reporte → Categoría simplificada

La columna ORIGEN_REPORTE tenía **74 valores distintos** (ej. “FISCALIA GENERAL DEL ESTADO DE TAMAULIPAS”). Se simplificó por tipo de institución:

Cuadro 4: Simplificación del origen del reporte

Categoría	Registros	%
FISCALIA	38,210	45.1 %
COMISION_LOCAL	32,847	38.8 %
PROCURADURIA	12,397	14.6 %
PORTAL	720	0.9 %
OTRO	564	0.7 %



4.4. Variables finales seleccionadas

Cuadro 5: Variables utilizadas en el análisis de reglas de asociación

Variable	Tipo original	Transformación	Valores
SEXO	Categórica	Directa	3
GRUPO_EDAD	Continua (fecha)	Discretización en 6 grupos	6
TEMPORADA	Fecha	Extracción mes $\rightarrow$ temporadas	4
ENTIDAD	Categórica	Directa	33
ORIGEN_SIMPLIFICADO	Categ. (74 vals)	Simplificación a 5 tipos	5
ESTATUS_VICTIMA	Categórica	Directa (variable objetivo)	2
MUNICIPIO	Categ. (1554 vals)	Descartada	—

5. Construcción de Transacciones

Este es el paso conceptualmente más importante: transformar el dataset tabular en una lista de transacciones que el algoritmo Apriori pueda procesar.

Idea central: cada fila (persona) se convierte en un conjunto de ítems del tipo COLUMNA=valor. Por ejemplo:

Fila original:

SEXO=HOMBRE, GRUPO_EDAD=26-40, TEMPORADA=VERANO, ENTIDAD=JALISCO, ORIGEN=FISCALIA, ESTATUS_VICTIMA=DESAPARECIDA

Transacción resultante:

{“SEXO=HOMBRE”, “GRUPO_EDAD=26-40”, “TEMPORADA=VERANO”, “ENTIDAD=JALISCO”, “ORIGEN_SIMPLIFICADO=FISCALIA”, “ESTATUS_VICTIMA=DESAPARECIDA”}

Los campos con valor nulo simplemente **no generan ítem** — no se imputan con ningún valor artificial. El resultado final fue **84,738 transacciones** con un promedio de 5.6 ítems cada una.



6. Algoritmos Aplicados

Se usaron $\text{min_support} = 0.05$ (5%), $\text{min_confidence} = 0.60$ (60%) y $\text{min_lift} = 1.0$ en los tres algoritmos.

6.1. Apriori — Implementación propia

Base teórica

El algoritmo Apriori fue propuesto por **Agrawal y Srikant (1994)** en el artículo “*Mining association rules between sets of items in large databases*”. Se basa en la **propiedad antimonótona del soporte**:

Propiedad Apriori (poda): si un conjunto de ítems **no** es frecuente, ningún superconjunto que lo contenga puede ser frecuente.
Equivalentemente: si $\{A\}$ no supera el soporte mínimo, los conjuntos $\{A, B\}$, $\{A, B, C\}$, etc. quedan podados sin necesidad de contarlos.

Funcionamiento nivel por nivel

El algoritmo trabaja iterativamente, un nivel por cada tamaño de itemset k :

1. $k = 1$: contar todos los ítems individuales. Conservar los frecuentes.
2. $k = 2$: combinar pares de ítems frecuentes del paso anterior. Verificar la propiedad Apriori (poda). Contar soporte de los que pasan.
3. $k = 3, 4, \dots$: repetir hasta que no queden candidatos frecuentes.

Resultados por nivel en nuestro dataset

Cuadro 6: Itemsets frecuentes encontrados por nivel en la implementación propia

Nivel k	Descripción	Itemsets frecuentes
$k = 1$	Ítems individuales	23
$k = 2$	Pares de ítems	60
$k = 3$	Tríos de ítems	42
$k = 4$	Cuartetos de ítems	7
Total		132



6.2. Comparación de los tres algoritmos

Cuadro 7: Comparación de algoritmos con los mismos parámetros

Algoritmo	Itemsets	Reglas	Tiempo (s)	Razón de velocidad
Apriori Propio	132	99	2.26	Python puro, loops sin optimizar
Apriori mlxtend	132	99	0.93	NumPy vectorizado (operaciones en C)
FP-Growth mlxtend	132	99	0.45	FP-Tree, solo 2 escaneos del dataset

¿Por qué FP-Growth es el más rápido?

Apriori escanea la base de datos $k + 1$ veces (una por cada nivel). **FP-Growth** la escanea solo **dos veces**:

1. Primera pasada: construye el FP-Tree, una estructura comprimida que almacena toda la información de co-ocurrencia.
2. Segunda pasada: extrae los itemsets frecuentes por minería recursiva de patrones condicionales, sin volver a revisar los datos originales.

¿Generan las mismas reglas?

Sí. Los tres algoritmos son *correctos y completos*: con los mismos parámetros garantizan encontrar exactamente los mismos 132 itemsets frecuentes y las mismas 99 reglas. La diferencia es puramente de **eficiencia computacional**, no de resultados.

7. Métricas de Evaluación

Para determinar si una regla $A \Rightarrow B$ es útil se usan tres métricas:

7.1. Soporte

Mide qué tan frecuente es la combinación en todo el dataset:

$$s(A \Rightarrow B) = \frac{|\{T \in D \mid A \cup B \subseteq T\}|}{|D|}$$



Un soporte bajo indica que el patrón es raro y probablemente no significativo. Usamos **mínimo 5 %** (4,237 transacciones).

7.2. Confianza

Mide la probabilidad condicional de que ocurra B dado que ocurrió A :

$$c(A \Rightarrow B) = \frac{s(A \Rightarrow B)}{s(A)}$$

Una confianza alta indica una regla fuerte. Usamos **mínimo 60 %**.

7.3. Lift

Mide si la asociación es real o simplemente producto de la frecuencia individual de cada ítem:

$$lift(A \Rightarrow B) = \frac{s(A \cup B)}{s(A) \times s(B)}$$

- $lift > 1$: asociación positiva real — ocurren juntos más de lo esperado
- $lift = 1$: A y B son independientes, es coincidencia
- $lift < 1$: asociación negativa

El lift es la métrica más importante para identificar reglas realmente interesantes. Usamos **mínimo 1.0**.

8. Reglas de Asociación

Se generaron **99 reglas** con soporte $\geq 5 \%$, confianza $\geq 60 \%$ y lift $\geq 1,0$.




8.1. Las 15 reglas con mayor Lift

Cuadro 8: Top 15 reglas de asociación ordenadas por lift descendente. Abreviaciones: TAM=TAMAULIPAS, MICH=MICHOACÁN, SIN=SINALOA, PROC=PROCURADURIA, DESAP=DESAPARECIDA.

Antecedente		Consecuente		Sop.	Conf.	Lift	Casos
ENTIDAD=TAM		ESTATUS=DESAP, ORIGEN=PROC, XO=HOMBRE	SE-	0.069	0.712	4.432	5,815
ENTIDAD=TAM		ESTATUS=DESAP, GEN=PROC	ORI-	0.087	0.899	4.391	7,347
ENTIDAD=TAM, XO=HOMBRE	SE-	ESTATUS=DESAP, GEN=PROC	ORI-	0.069	0.899	4.389	5,815
ENTIDAD=TAM, TUS=DESAP	ESTA-	ORIGEN=PROC, XO=HOMBRE	SE-	0.069	0.714	4.344	5,815
ENTIDAD=TAM		ORIGEN=PROC, XO=HOMBRE	SE-	0.069	0.712	4.331	5,816
ENTIDAD=TAM, TUS=DESAP	ESTA-	ORIGEN=PROC		0.087	0.902	4.298	7,347
ENTIDAD=TAM, TATUS=DESAP, XO=HOMBRE	ES- SE-	ORIGEN=PROC		0.069	0.900	4.290	5,815
ENTIDAD=TAM		ORIGEN=PROC		0.087	0.900	4.289	7,356
ENTIDAD=TAM, XO=HOMBRE	SE-	ORIGEN=PROC		0.069	0.899	4.283	5,816
ENTIDAD=MICH		ORIGEN=PROC		0.059	0.843	4.017	4,964
ENTIDAD=MICH, TUS=DESAP	ESTA-	ORIGEN=PROC		0.055	0.839	3.997	4,676
ENTIDAD=MICH		ESTATUS=DESAP, GEN=PROC	ORI-	0.055	0.794	3.879	4,676
ENTIDAD=SIN		SEXO=HOMBRE		0.051	0.913	1.196	4,299
GRUPO_EDAD=41-60		ESTATUS=DESAP, XO=HOMBRE	SE-	0.095	0.826	1.151	8,075
GRUPO_EDAD=41-60		SEXO=HOMBRE		0.101	0.878	1.151	8,587



Tarea 03 - Semestre 2026-2





8.2. Patrón: ENTIDAD $\wedge$ TEMPORADA $\Rightarrow$ ESTATUS_VICTIMA

Cuadro 9: Reglas con ESTATUS_VICTIMA en el consecuente. Abreviaciones: TAM=TAMAULIPAS, MICH=MICHOACÁN, PROC=PROCURADURIA, DESAP=DESAPARECIDA.

Antecedente	Consecuente	Sop.	Conf.	Lift	Casos
ENTIDAD=TAM	ESTATUS=DESAP, ORIGEN=PROC, SEXO=HOMBRE	0.069	0.712	4.432	5,815
ENTIDAD=TAM	ESTATUS=DESAP, ORIGEN=PROC	0.087	0.899	4.391	7,347
ENTIDAD=TAM, SEXO=HOMBRE	ESTATUS=DESAP, ORIGEN=PROC	0.069	0.899	4.389	5,815
ENTIDAD=MICH	ESTATUS=DESAP, ORIGEN=PROC	0.055	0.794	3.879	4,676
GRUPO_EDAD=41-60	ESTATUS=DESAP, SEXO=HOMBRE	0.095	0.826	1.151	8,075
GRUPO_EDAD=26-40	ESTATUS=DESAP, SEXO=HOMBRE	0.190	0.802	1.118	16,111
GRUPO_EDAD=26-40, TEMPORADA=VERANO	ESTATUS=DESAP, SEXO=HOMBRE	0.053	0.801	1.116	4,532
ENTIDAD=MICH	ESTATUS=DESAP, SEXO=HOMBRE	0.055	0.793	1.105	4,668

9. Interpretación de las Reglas

9.1. Hallazgo principal: Tamaulipas y Procuraduría

Las **9 reglas con mayor lift** (entre 4.28 y 4.43) involucran a Tamaulipas y a la Procuraduría como origen del reporte. Esto significa que esta combinación ocurre **más de 4 veces** de lo que se esperaría si los factores fueran independientes.

Regla más fuerte:

ENTIDAD=TAMAULIPAS $\Rightarrow$ {ESTATUS=DESAPARECIDA, ORIGEN=PROCURADURIA, SEXO=HOMBRE}
 Soporte: 0.069 (5,815 casos) Confianza: 71.2 % Lift: **4.432**

Interpretación: en Tamaulipas, el 90 % de los casos están reportados por la Procuraduría (en lugar de Fiscalía o Comisión Local, que son las instituciones predominantes en



el resto del país). Esto podría reflejar una estructura institucional diferente en ese estado, no necesariamente un patrón del fenómeno de desaparición.

9.2. Michoacán y Procuraduría


El mismo patrón aparece en Michoacán con lift de 4.0, indicando que también tiene una alta concentración de reportes vía Procuraduría comparado con el resto del país.

9.3. Hombres adultos (26-60 años)

Las reglas con GRUPO_EDAD=26-40 y GRUPO_EDAD=41-60 tienen confianza superior al 80 % hacia SEXO=HOMBRE, lo que refleja que las desapariciones en estos grupos de edad son predominantemente masculinas. El grupo 26-40 es el más representado con 16,111 casos en su regla más frecuente.

9.4. Sesgo del sistema de registro

Reflexión crítica: las reglas de asociación describen lo que **se registra**, no necesariamente lo que ocurre en la realidad. Un estado con más registros puede tener mejor infraestructura de reporte. El patrón Tamaulipas-Procuraduría podría reflejar una práctica institucional de registro, no un patrón del fenómeno de desaparición en sí. Adicionalmente, el 36.7% de datos CONFIDENCIAL excluidos podría tener un perfil demográfico completamente distinto.





10. Conclusiones

Cuadro 10: Respuestas a las preguntas de la tarea

Pregunta	Respuesta
¿Cuál algoritmo tarda más?	Apriori propio (2.26 s). Python puro sin vectorización ni optimización de bajo nivel.
¿Cuál tarda menos y por qué?	FP-Growth (0.45 s). Escanea el dataset solo 2 veces usando la estructura FP-Tree, evitando la generación explícita de candidatos.
¿Generan las mismas reglas?	Sí. Los tres son completos y correctos. La diferencia es únicamente de eficiencia computacional.
¿Cuántos itemsets frecuentes?	132 itemsets con soporte $\geq 5\%$ (distribuidos en 4 niveles).
¿Cuántas reglas útiles?	99 reglas con confianza $\geq 60\%$ y lift $\geq 1,0$.
Limitación principal	36.7 % de datos excluidos por ser CONFIDENCIAL. Los patrones aplican solo al 63.3 % público.

Las reglas de asociación permiten descubrir patrones de co-ocurrencia en datos complejos sin necesidad de definir una variable objetivo a priori. En el contexto de personas desaparecidas, estos patrones pueden orientar políticas de búsqueda focalizadas — siempre recordando que **asociación no implica causalidad** y que los patrones reflejan tanto el fenómeno real como las características del sistema de registro.

11. Clasificación: Predicción de **ESTATUS_VICTIMA**

11.1. Introducción

Esta sección presenta el modelo de clasificación construido para predecir **ESTATUS_VICTIMA** a partir de las características disponibles en el dataset del Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP). Se utiliza el mismo dataset limpio de 84,738 registros que se empleó en el análisis de reglas de asociación, excluyendo los 49,149 registros CONFIDENCIAL.

El objetivo es construir un modelo que prediga si una víctima registrada tiene estatus **DESAPARECIDA** o **NO LOCALIZADA**, e interpretar si el modelo captura patrones




reales del fenómeno o sesgos del sistema de registro.

11.2. Justificación de Métricas

La distribución de la variable objetivo presenta un desbalance severo:

Cuadro 11: Distribución de la variable objetivo ESTATUS_VICTIMA

Clase	Registros	Porcentaje
DESAPARECIDA	79,881	94.27 %
NO LOCALIZADA	4,857	5.73 %
Total	84,738	100 %



Con una razón de desbalance de 16:1, la **exactitud (accuracy)** es una **métrica engañosa**. Un clasificador trivial que siempre prediga DESAPARECIDA obtendría ~94 % de accuracy sin detectar ningún caso NO LOCALIZADA — la llamada *Paradoja de la Exactitud*



Paradoja de la Exactitud:

$$\text{Accuracy}_{\text{trivial}} = \frac{79,881}{84,738} \approx 94,3\% \quad \text{con Recall(NO LOCALIZADA)} = 0$$

Un modelo con 94 % de accuracy puede no haber aprendido nada.

Las métricas seleccionadas son:

1. **F1 (NO LOCALIZADA) ★** — media armónica de Precision y Recall sobre la clase positiva. El F1-macro puede esconder un F1= 0 en la clase minoritaria.
2. **Recall (NO LOCALIZADA)** — un Falso Negativo implica que un expediente NO LOCALIZADA no se cierra, lo que genera asignación incorrecta de recursos de búsqueda.
3. **PR-AUC ★** — más informativa que ROC-AUC en datos desbalanceados porque no incluye los Verdaderos Negativos en su cálculo. Con 94 %/6 %, los TN inflarían artificialmente la curva ROC.
4. **ROC-AUC** — capacidad discriminativa global para comparar modelos sin fijar un umbral.
5. **Accuracy** — únicamente como referencia.

Cuadro 12: Criterio de selección de métricas según el costo del error

Error	Consecuencia en el dominio	Métrica que lo penaliza
FN (NOLOC → DESAP)	Expediente no se cierra; recursos mal asignados; sesgo estadístico	Recall, F1
FP (DESAP → NOLOC)	Expediente cerrado por error; pérdida de seguimiento del caso	Precision, F1
Ambos errores son graves → se prefiere F1 sobre Recall puro		PR-AUC > ROC-AUC

11.3. Preprocesamiento

Se utilizaron las mismas variables que se construyeron en las secciones 4 y 5, con las siguientes decisiones:



Cuadro 13: Variables utilizadas en el modelo de clasificación

Variable	Tipo	Transformación	Nulos
SEXO	Catégorica	LabelEncoder (3 valores)	0
GRUPO_EDAD	Catégorica	LabelEncoder + SIN_DATO	34,125 (40.3 %)
ANIO_DESAPARICION	Numérica	Mediana = 2018	8,160 (9.6 %)
TEMPORADA	Catégorica	LabelEncoder + SIN_DATO	8,160 (9.6 %)
ENTIDAD	Catégorica	LabelEncoder (33 valores)	0
ORIGEN_SIMPLIFICADO	Catégorica	LabelEncoder (5 valores)	0
MES_DESAPARICION	<i>Excluida: colineal con TEMPORADA</i>		
MUNICIPIO	<i>Excluida: cardinalidad muy alta, 1554 valores</i>		

Decisión sobre MES_DESAPARICION: esta variable fue excluida porque TEMPORADA ya captura la información temporal agrupada en cuatro estaciones. Incluir ambas introduciría colinealidad y sesgaría artificialmente la importancia de variables.

Imputación de nulos catégoricos: los nulos de GRUPO_EDAD y TEMPORADA se imputaron con la categoría explícita SIN_DATO, preservando la información de ausencia en lugar de eliminarla o imputar con la moda.

11.4. División Entrenamiento / Prueba

Se siguió el mismo esquema del notebook de clase (`cart_sonar.ipynb`): división 80 %/20 % estratificada, garantizando que la proporción 94.3 %/5.7 % se mantenga en ambos conjuntos.

Cuadro 14: División del dataset para entrenamiento y prueba

Conjunto	Registros	DESAPARECIDA	NO LOCALIZADA
Entrenamiento (80 %)	67,790	94.27 %	5.73 %
Prueba (20 %)	16,948	94.27 %	5.73 %

Se usó validación cruzada estratificada de 5 particiones (`StratifiedKFold`, $k = 5$) para la búsqueda de hiperparámetros, igual que en el notebook de clase.

11.5. Modelos Entrenados

Se entrenaron tres modelos, ordenados de menor a mayor complejidad:




Modelo 1 — Árbol de Decisión por defecto (CART, Gini)

Árbol CART sin restricciones de profundidad, con criterio Gini y `class_weight='balanced'` para compensar el desbalance 16:1. Este modelo sirve como línea base y referencia de comparación.

Modelo 2 — Árbol podado por complejidad de coste (α^*)


La poda por complejidad de coste controla el sobreajuste eliminando ramas cuya ganancia es menor que su coste de complejidad α . El parámetro óptimo se buscó con `GridSearchCV` y validación cruzada estratificada de 5 particiones, usando ROC-AUC como criterio de selección:

$$\alpha^* = 0,000235 \implies \text{AUC promedio en validación} = 0,9299$$





Tarea 03 - Semestre 2026-2



Modelo 3 — Random Forest con búsqueda de hiperparámetros

Random Forest construye múltiples árboles sobre submuestras bootstrap y promedia sus predicciones, reduciendo la varianza del árbol individual. Se buscaron los mejores valores de $n_estimators \in \{50, 100\}$ y $max_depth \in \{8, 12\}$ con GridSearchCV.

Mejores parámetros: $n = 100$, $max_depth = 12 \implies$ AUC promedio en validación = 0,9272

11.6. Resultados y Comparación de Modelos

Cuadro 15: Comparación de modelos sobre el conjunto de prueba (16,948 registros). Ordenada por PR-AUC ★, métrica principal.


Modelo	Accuracy	F1 NOLOC ★	Recall	Prec.	ROC-AUC	PR-AUC ★
Árbol podado (α^*)	0.8413	0.3939	0.9001	0.2521	0.9299	0.4934
Random Forest ($n = 100$, $d = 12$)	0.8677	0.4277	0.8630	0.2843	0.9272	0.4863
Árbol por defecto	0.8811	0.4329	0.7920	0.2978	0.8646	0.4223


Baseline PR-AUC (clasificador aleatorio) = 0.0573

Los tres modelos superan ampliamente el baseline de PR-AUC = 0.0573, lo que indica que están aprendiendo patrones reales. El **Árbol podado** es el mejor modelo según PR-AUC (0.4934) y ROC-AUC (0.9299).



El árbol podado tiene menor accuracy (0.84) que el árbol por defecto (0.88), pero mayor PR-AUC. Esto ilustra la paradoja de la exactitud: el modelo “menos preciso” es el más útil para detectar casos NO LOCALIZADA.






Matriz de confusión — Árbol podado (mejor modelo)

Cuadro 16: Matriz de confusión del árbol podado sobre el conjunto de prueba

	Pred. DESAPARECIDA	Pred. NO LOCALIZADA
Real DESAPARECIDA	TN = 13,384	FP = 2,593
Real NO LOCALIZADA	FN = 97	TP = 874



Interpretación:

- **TP = 874**: casos NO LOCALIZADA detectados correctamente.
- **FN = 97**: casos NO LOCALIZADA predichos como DESAPARECIDA — expedientes que no se cerrarían; recursos de búsqueda mal asignados (el peor error en este dominio).
- **FP = 2,593**: casos DESAPARECIDA predichos como NO LOCALIZADA — expedientes cerrados por error.
- **TN = 13,384**: casos DESAPARECIDA clasificados correctamente.


El modelo recupera el **90 % de los casos NO LOCALIZADA** (Recall = 0.90), a costa de generar 2,593 falsas alarmas. Este trade-off es aceptable en un sistema de registro donde perder un caso NO LOCALIZADA (FN) tiene mayor costo operativo que un cierre erróneo (FP) revisable.



11.7. Importancia de Variables

Cuadro 17: Importancia de variables según el Random Forest (reducción media del índice Gini)

Variable	Importancia	Porcentaje
ENTIDAD	0.4876	48.8 %
ANIO_DESAPARICION	0.2683	26.8 %
ORIGEN_SIMPLIFICADO	0.1261	12.6 %
GRUPO_EDAD	0.0667	6.7 %
TEMPORADA	0.0380	3.8 %
SEXO	0.0132	1.3 %



ENTIDAD (48.8 %) y **ANIO_DESAPARICION** (26.8 %) dominan la predicción, acumulando el 75.6 % de la importancia total. Esto indica que el **ESTATUS_VICTIMA** depende principalmente del *contexto geográfico e histórico del registro*, no de las características individuales de la víctima (sexo, edad).

Las variables individuales de la víctima (**SEXO** = 1.3 %, **GRUPO_EDAD** = 6.7 %) tienen una importancia marginal, lo cual refuerza la interpretación de que el modelo captura principalmente prácticas institucionales de actualización de expedientes.




11.8. Optimización del Umbral de Decisión

El umbral $\theta = 0,5$ es una convención estadística, no el punto óptimo para el dominio. Se buscó el umbral que maximiza el F1 de la clase positiva:

$$\theta^* = \arg \max_{\theta} F1_{\text{NO LOCALIZADA}}(\theta)$$

Cuadro 18: Comparación de umbrales de decisión sobre el mejor modelo

Umbral	F1 NOLOC	Recall	Precision
$\theta = 0,50$ (default)	0.3939	0.9001	0.2521
$\theta^* = 0,90$ (óptimo)	0.5300	0.5366	0.5236



Con $\theta^* = 0,90$, el F1 mejora de 0.39 a 0.53 al balancear mejor Precision y Recall. La elección del umbral en producción es estratégica: si se prioriza no perder casos NO LOCALIZADA, se usa $\theta = 0,50$ (Recall = 0.90); si se prioriza confiabilidad de las predicciones positivas, se usa $\theta = 0,90$.

11.9. Interpretación de los Resultados

1. Paradoja de la exactitud confirmada

El árbol por defecto alcanza 88% de accuracy, pero el árbol podado, con 84% de accuracy, detecta más casos NO LOCALIZADA (Recall = 0.90 vs. 0.79) y tiene mayor PR-AUC (0.49 vs. 0.42). Usar accuracy como criterio de selección habría llevado a elegir el modelo incorrecto.



2. El modelo captura sesgos del sistema de registro

La dominancia de ENTIDAD (48.8 %) y ANIO_DESAPARICION (26.8 %) sugiere que el modelo está aprendiendo *quién actualiza los expedientes y cuándo*, no el fenómeno real de desaparición:

- **Sesgo geográfico:** estados con mejor gestión burocrática tienen más expedientes actualizados a NO LOCALIZADA. El modelo aprende ese patrón institucional, no la situación real de las víctimas.
- **Sesgo temporal:** la importancia de ANIO_DESAPARICION refleja cambios en las prácticas de registro a lo largo del tiempo, no cambios en el fenómeno de desaparición.
- **ORIGEN_SIMPLIFICADO** (12.6 %): consistente con el hallazgo de en la sección 9.1 — Tamaulipas y Michoacán reportan vía Procuraduría (lift > 4), y este patrón institucional también es capturado por el clasificador.

ESTATUS_VICTIMA es un estado **administrativo**, no la situación real de la persona. Las reglas de asociación (secciones 1–10) y este clasificador describen lo que **se registra**, no necesariamente lo que **ocurre en la realidad**. Un estado con más registros actualizados puede tener mejor infraestructura de reporte, no necesariamente más personas localizadas. El 36.7 % de datos CONFIDENCIAL excluidos podría tener un perfil completamente distinto.

3. Consistencia con el análisis de reglas de asociación

Los hallazgos del clasificador son consistentes:

- Las reglas con mayor lift (4.28–4.43) involucran a ENTIDAD=TAMAULIPAS y ORIGEN=PROCURADURIA. El clasificador también identifica ENTIDAD como la variable más importante (48.8 %).
- La sección 9.4 concluye que las reglas reflejan “lo que se registra, no lo que ocurre”. El clasificador llega a la misma conclusión por una ruta independiente.



11.10. Conclusiones de la Sección de Clasificación

Cuadro 19: Respuestas a los requerimientos

Requerimiento	Respuesta
División train/test	80 %/20 % estratificada con <code>stratify=y</code>
Métricas reportadas	F1 (NO LOCALIZADA), Recall, Precision, PR-AUC, ROC-AUC, Accuracy (5 métricas con justificación explícita)
Métricas justificadas	Sección metrics: desbalance 16:1 invalida accuracy; PR-AUC > ROC-AUC en datos desbalanceados
Variables relevantes	ENTIDAD (48.8 %) y ANIO_DESAPARICION (26.8 %) dominan — sugieren sesgo de registro
Patrones reales vs. sesgos	El modelo captura prácticas institucionales de actualización, no el fenómeno real (sección interpretación)
Mejor modelo	Árbol podado ($\alpha^* = 0,000235$): PR-AUC = 0.4934, Recall NOLOC = 0.90

Conclusiones Generales

Los patrones descubiertos reflejan fundamentalmente el *sistema de registro*, no el fenómeno real de desaparición. Las entidades con mayor presencia en las reglas de alta confianza (Tamaulipas, Michoacán) también son las más importantes para el clasificador. El origen del reporte, que en las reglas de asociación tenía lift de 4.0–4.4, es la tercera variable en importancia para el Random Forest.

Referencias

- [1] Bamber, D. (1975). The area above the ordinal dominance graph and the area below the receiver operating characteristic graph. *Journal of Mathematical Psychology*, 12(4), 387–415.
- [2] Breiman, L., Friedman, J., Olshen, R., & Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.
- [3] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [4] Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874.



- [5] Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- [6] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer.
- [7] Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.
- [8] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432.